

NLP • BERT • SINIFLANDIRMA

House MD Veri Seti ile BERT Tabanlı Semptom Sınıflandırma

House MD klinik diyaloglarından semptom sınıfı tahmini yapan
uçtan uca BERT tabanlı NLP prototipi

MODEL

BERT Fine-tuned

SINIF

Top 30 + Diğer

ARAYÜZ

Streamlit

VERİ

7282 satır

Faruk Laçın • 030122117
Hüseyin Lab İzü • 030121037
Ömer Faruk Pehlivan • 030123083

Proje Akışı

Uçtan uca NLP süreci — 7 aşama

01

Veri Hazırlama

House MD veri seti yüklendi

02

Metin Temizleme

clean_text üretildi

03

Etiket Temizleme

Geçersiz Symptom değerleri elendi

04

BERT Fine-Tuning

AutoModelForSequenceClassification

05

Test Metrikleri

Accuracy, F1, Top-3

06

Görselleştirme

Confusion matrix + ısı haritası

07

Streamlit Arayüzü

Demo + etik katman

ÇIKTI → Çalışan BERT modeli + Streamlit demo + Etik katman + Değerlendirme görselleri

Veri Seti ve Kullanılan Alanlar

HAM VERİ

Ham Veri Bilgisi

Ham satır sayısı

7.282

Encoding

utf-8-sig

Ham veri

house_md_data.csv

KULLANILAN ALANLAR

Model Giriş / Hedef Yapısı

GİRİŞ

text

Ham konuşma / klinik metin

GİRİŞ

clean_text

Temizlenmiş BERT girdisi

HEDEF

Symptom

Modelin tahmin ettiği hedef sınıf

Model yalnızca metin üzerinden öğrenir. Görüntü, ses veya hasta kimlik bilgisi kullanılmaz.

Metin Temizleme: clean_text Nasıl Üretildi?

1

Unicode Normalizasyonu

Karakter biçimleri standartlaştırıldı

2

Küçük Harfe Çevirme

Metin tamamı lower-case yapıldı

3

Noktalama Temizliği

Noktalama işaretleri boşlukla değiştirildi

4

Boşluk Düzenleme

Ardışık boşluklar tek boşluğa indirildi

5

Strip

Baştaki ve sondaki boşluklar temizlendi

ÖRNEK

Original text:

29 yaşında bir kadın hasta; ilk nöbetini bir ay önce geçirmiş.

clean_text:

29 yaşında bir kadın hasta ilk nöbetini bir ay önce geçirmiş

*Noktalama ve unicode farklılıkları ortadan kalkar;
model metni daha standart biçimde işler.*

Hedef Etiket Temizleme ve Normalizasyon

ELELENEN DEĞERLER

Geçersiz Symptom Değerleri

boş hücre / nan / null

→ Eksik veri

- / none / symptom

→ Placeholder

belirti yok / yok

→ Semptom üretmez

tanı / tedavi / alay

→ Semptom değil

NORMALİZASYON ÖRNEKLERİ

Eşleştirme Tablosu

miyokard enfarktüsü

→ kalp krizi

heart attack

→ kalp krizi

solunum sıkıntısı

→ nefes darlığı

nefes alamama

→ nefes darlığı

seizure

→ nöbet

yüksek ateş

→ ateş

Normalizasyon aynı klinik anlamı taşıyan farklı yazımları tek sınıfta toplar.

Çoklu Semptom Ayırıştırma ve İşlenmiş Veri

ÇOKLU SEMPTOM AYRIŞTIRMA

ÖNCE

Aynı metin
+
ateş, öksürük



SONRA

Aynı metin
+ ateş

Aynı metin
+ öksürük

*Her eğitim satırının tek hedef sınıfı olması gerekir.
Bu işlem veriyi single-label yapıya uygun hale getirir.*

VERİ HAZIRLIĞI SONUÇLARI

Ham satır 7.282

İşlenmiş satır 4.941

Ayrıştırma öncesi 4.036

Eklenen satır + 905

Toplam semptom etiketi 2.446

Final: Top 30 Semptom + "diğer" → 31 Sınıf

BERT Girdisi ve Kullanılan Teknolojiler

BERT GİRDİSİ

Tokenizer Akışı

clean_text



Tokenizer
(max_length: 128)



input_ids
+ attention_mask



BERT Model

TEKNOLOJİLER

Kullanılan Teknolojiler

PyTorch

BERT eğitimi ve inference

Hugging Face

Tokenizer ve model

Pandas

Veri okuma ve ön işleme

Scikit-learn

Metrik hesaplama

Seaborn / Matplotlib

Görselleştirme

Streamlit

Web arayüzü

CUDA

GPU hızlandırmalı eğitim

BERT Modelleme ve Eğitim Ayarları

EĞİTİM PARAMETRELERİ

Eğitim modu Full BERT fine-tuning

Cihaz CUDA (GPU)

Encoder Dondurulmadı

Loss CrossEntropyLoss

Çıkış Softmax

Batch size 4


Learning rate 2e-5

Max epoch 8

Çalışan epoch 7

Early stopping patience = 3

VALIDATION F1 GEÇMİŞİ



En iyi model: Epoch 4 (Weighted F1: 0.762)

Model Başarı Metrikleri

Accuracy

%75.74

Test setinde doğru tahmin oranı

Weighted F1

%75.14

Sınıf destek sayılarını dikkate alır

Macro F1

%32.11

Her sınıfı eşit ağırlıkla değerlendirir

Top-3 Accuracy

%91.91

Doğru sınıfın ilk 3 tahmin içinde oranı

Metrik Yorumu

Accuracy & Weighted F1:

Yüksek: Genel performans güçlü. Sınıf dağılımına ağırlık verir.


Macro F1 (%32):

Düşük: Nadir sınıflardaki başarısızlığı yansıtır — beklenen bir durum.


Top-3 Accuracy (%92):

Çok yüksek: Model doğru sınıfı hep üst sıralarda tahmin eder.

BERT Test Confusion Matrix



Sınıf Bazlı Metrik Isı Haritası



Örnek BERT Tahminleri ve Streamlit Arayüzü

ÖRNEK TAHMİNLER

Girdi:

hastanın kalp krizi geçirdiği kesin

kalp krizi

%97.90

Girdi:

hasta nefes almakta zorlanıyor

nefes darlığı

%99.38

Girdi:

hasta çift görüyor ve diplopi yaşıyor

diğer

%99.55

STREAMLİT ARAYÜZÜ



Kullanıcı metin girer



BERT tahminleri tablo gösterilir



BERT yüzdeleri grafik gösterilir



'diğer' için açıklama verilir



Düşük güvende uyarı gösterilir

```
.\.venv\Scripts\python.exe -m streamlit run app.py
```

Streamlit

Diyalog metni

hasta nefes almakta zorlanıyor


Tahmin

5

Analiz Et

BERT Tahminleri

Sıra	Semptom	BERT (%)	Label ID
1	nefes darlığı	99.38	23
2	öksürük	0.06	30
3	diğer	0.06	8
4	aritmî	0.04	1
5	kalp durması	0.03	15



Precision, Re

Eğitim Bölünmesi

Train

3.483

satır

*3458 original
+ 25 synthetic*

Validation

741

satır

En iyi modeli seçmek

Test

742

satır

Final performans ölçümü

Train → Model ağırlıklarını günceller

Validation → En yüksek F1 değeri veren epoch modeli seçer

Test → Seçilen model üzerinde tek seferlik final değerlendirme yapılır

Etik, Sınırlılıklar ve Final Sonuç

ETİK SINIRLAR

- Sistem tanı koymaz
- Sistem tedavi önermez
- Doktor yerine geçmez
- Kullanıcı metnini kaydetmez
- Kişisel veri uyarısı verir
- Acil durumda 112 yönlendirir

SINIRLILIKLAR

- House MD verisi gerçek klinik veri değil
- Model single-label çalışır
- Tüm semptomları bağımsız çıkarmaz
- Az örnekli sınıflarda başarı düşer

House MD veri seti üzerinde BERT-only yaklaşımla geliştirilmiş, top 30 + diğer semptom sınıflandırması yapan, Streamlit arayüzlü ve etik uyarıları bulunan uçtan uca NLP prototipi tamamlanmıştır.

NLP

BERT

SEMPATOM

Faruk Laçin • 030122117
Hüseyin Yusuf Cihangir • 030121037
Ömer Faruk Pehlivan • 030123083

Teşekkürler

Sorularınız için hazırız.

75.74%

Accuracy

91.91%

Top-3 Acc

31

Sınıf